Лабораторная работа №7. Рекуррентные нейронные сети для анализа текста

Данные: Набор данных для предсказания оценок для отзывов, собранных с сайта imdb.com, который состоит из 50,000 отзывов в виде текстовых файлов. Отзывы разделены на положительные (25,000) и отрицательные (25,000). Данные предварительно токенизированы по принципу "мешка слов", индексы слов можно взять из словаря (imdb.vocab). Обучающая выборка включает в себя 12,500 положительных и 12,500 отрицательных отзывов, контрольная выборка также содержит 12,500 положительных и 12,500 отрицательных отзывов, а также. Данные можно скачать по ссылке https://ai.stanford.edu/~amaas/data/sentiment/)

In [1]:

```
import torch
from torchtext import data
from torchtext import datasets
import torch.optim as optim
import torch.nn as nn
from torch.utils.tensorboard import SummaryWriter
```

Загрузите данные. Преобразуйте текстовые файлы во внутренние структуры данных, которые используют индексы вместо слов.

'entry', 'in',

e', 'battle', '-', 'weary', 'Detective', 'Harry', 'Callahan', ',',

'the', "'", 'Dirty', 'Harry', "'", 'series', '.', "'", 'Sudden',

'but', 'would', 'also', 'direct', 'the', 'fourth',

Impact', "'", 'again', 'like', 'the', 'other', 'additions', ',', ' brings', 'its', 'own', 'distinguishable', 'style', 'and', 'tone', ',', 'but', 'if', 'anything', 'it', "'s", 'probably', 'the', 'most ', 'similar', 'to', 'the', 'original', 'in', 'it', "'s", 'darker', 'and', 'seedy', 'moments', '(', 'and', 'bestowing', 'a', 'classic' , 'line', '"', 'Go', 'ahead', '.', 'Make', 'my', 'day', '"', ')',
'\x85 ', 'but', 'some', 'of', 'its', 'humor', 'has', 'to', 'been',
'seen', 'to', 'believe', '.', 'A', 'bulldog', '\x85 ', 'named', 'm
eathead', 'that', 'pisses', 'and', 'farts', '.', 'Oh', 'yeah', '.' , 'However', 'an', 'interesting', 'fact', 'this', 'entry', 'was', 'only', 'one', 'in', 'series', 'to', 'not', 'have', 'it', entirely', 'in', 'San', 'Francisco.<br', '/><br', '/>The', 'story' , 'follows', 'that', 'of', 'detective', 'Callahan', 'trying', 'to' , 'put', 'the', 'pieces', 'together', 'of', 'a', 'murder', 'where'
, 'the', 'victim', 'was', 'shot', 'in', 'the', 'groin', 'and', 'th en', 'between', 'the', 'eyes', '.', 'After', 'getting', 'in', 'som e', 'trouble', 'with', 'office', 'superiors', 'and', 'causing', 'a ', 'stir', 'which', 'has', 'some', 'crime', 'lord', 'thugs', 'afte r', 'his', 'blood', '.', 'He', "'s", 'ordered', 'to', 'take', 'lea ve', ',', 'but', 'it', 'falls', 'into', 'a', 'working', 'one', 'wh ere', 'he', 'heads', 'to', 'a', 'coastal', 'town', 'San', 'Paulo', ',', 'where', 'a', 'murder', 'has', 'occurred', 'similar', 'in', 'vein', '(', 'bullet', 'to', 'groin', 'and', 'between', 'eyes', ')', 'to', 'his', 'case', '.', 'There', 'he', 'begins', 'to', 'dig', 'up', 'dirt', ',', 'which', 'leads', 'to', 'the', 'idea', 'of', 's omeone', 'looking', 'for', 'revenge.

'up', 'dirt', ',', 'for', 'leads', 'to', 'the', 'idea', 'of', 's omeone', 'looking', 'for', 'revenge.

', '/>

', 'Not', 'someone', 'looking', 'for', 'revenge.

', '/>

', 'hot', 'someone', 'looking', 'for', 'revenge.

', '/>

', 'looking', 'for', 'revenge.

', '/>

', 'hot', 'someone', 'looking', 'for', 'revenge.

', '/>

', '/>

', '/>

', '/>To', 'be', 'someone', 'looking', 'for', 'revenge.

', '/>

', 'but', 'after', 'many', 'repeat ', 'viewings', 'it', 'virtually', 'has', 'grown', 'on', 'me', 'to' , 'the', 'point', 'of', 'probably', 'being', 'on', 'par', 'with', 'the', 'first', 'sequel', "'", 'Magnum', 'Force', "'", '.', 'This' , 'well', '-', 'assembled', 'plot', 'actually', 'gives', 'Eastwood
', 'another', 'angle', 'to', 'work', 'upon', '(', 'even', 'though' , 'it', 'feels', 'more', 'like', 'a', 'sophisticated', 'take', 'on ', 'the', 'vigilante', 'features', 'running', 'rampant', 'at', 'th at', 'time', ')', ',', 'quite', 'literal', 'with', 'something', 'p unishing', 'but', 'luridly', 'damaging', '.', 'It', "'s", 'like', 'he', "'s", 'experimenting', 'with', 'noir', '-', 'thriller', 'tou ches', 'with', 'character', '-', 'driven', 'traits', 'to', 'help', 'develop', 'the', 'emotionally', 'bubbling', 'and', 'eventual', 'm orality', 'framework', '.', 'His', 'use', 'of', 'images', 'is', 'l asting', ',', 'due', 'to', 'its', 'slickly', 'foreboding', 'atmosp herics', '.', 'Dark', 'tones', ',', 'brooding', 'lighting', '\x85 ', 'like', 'the', 'scene', 'towards', 'the', 'end', 'akin', 'to', 'some', 'western', 'showdown', 'of', 'a', 'silhouette', 'figure', '(', 'Harry', 'with', 'his', 'new', '.44', 'automag', 'handgun', ')', 'moving', 'its', 'way', 'towards', 'the', 'stunned', 'prey', ' on', 'the', 'fishing', 'docks', '.', 'It', "'s", 'a', 'striking', 'sight', 'that', 'builds', 'fear', '!', 'Mixing', 'the', 'haunting ly', 'cold', 'with', 'plain', 'brutality', 'and', 'dash', 'of', 'h umor', '.', 'It', 'seemed', 'to', 'come', 'off', '.', 'A', 'major', 'plus', 'with', 'these', 'films', 'are', 'the', 'dialogues', ',' , 'while', 'I', 'would', "n't", 'call', "'", 'Sudden', 'Impact', "
'", 'first', '-', 'rate', ',', 'it', 'provides', 'ample', 'biting' , 'exchanges', 'and', 'memorably', 'creditable', 'lines', ' \xspace x85 ', '"', 'You', "'re", 'a', 'legend', 'in', 'your', 'own', 'mind', '"', '.', 'Do', "n't", 'you', 'just', 'love', 'hearing', 'Harry', 'sp

arking', 'an', 'amusing', 'quip', ',', 'before', 'pulling', 'out', 'his', 'piece', '.', 'The', 'beating', 'action', 'when', 'it', 'oc curs', 'is', 'excitingly', 'jarring', 'and', 'intense', '\x85', 'the', 'only', 'way', 'to', 'go', 'and', 'the', 'pacing', 'flies', 'by', 'with', 'little', 'in', 'the', 'way', 'of', 'flat', 'passage s', '.', 'Lalo', 'Schfrin', 'would', 'return', 'as', 'composer', '
(', 'after', "'", 'The', 'Enforcer', '"', 'had', 'Jerry', 'Fieldin g', 'scoring', ')', 'bringing', 'a', 'methodical', 'funky', 'kick', ',', 'which', 'still', 'breathed', 'those', 'gloomy', 'cues', 't o', 'a', 'texturally', 'breezy', 'score', 'that', 'clicked', 'from ', 'the', 'get', '-', 'go', '.', 'Bruce', 'Surtees', '(', 'an', 'E astwood', 'regular', ')', 'gets', 'the', 'job', 'behind', 'the', 'camera', '(', 'where', 'he', 'did', 'a', 'piecing', 'job', 'with', "'", 'Dirty', 'Harry', "'", ')', 'and', 'gives', 'the', 'film', 'p lenty', 'of', 'scope', 'by', 'wonderfully', 'framing', 'the', 'bac kdrops', 'in', 'some', 'impeccable', 'tracking', 'scenes', ',', 'b ut', 'also', 'instrument', 'edgy', 'angles', 'within', 'those', 'd ramatic', 'moments.<br', '/><br', '/>Eastwood', 'as', 'the', 'dino saur', 'Callahan', 'still', 'packs', 'a', 'punch', ',', 'going', ' beyond', 'just', 'that', 'steely', 'glare', 'to', 'get', 'the', 'j ob', 'done', 'and', 'probably', 'showing', 'a', 'little', 'more', 'heart', 'than', 'one', 'would', 'expect', 'from', 'a', 'younger', 'Callahan', '.', 'This', 'going', 'by', 'the', 'sudden', 'shift', 'in', 'a', 'plot', 'turn', 'of', 'Harry', "'s", 'quest', 'for', 'j ustice', '\x85 ', 'by', 'the', 'badge', 'even', 'though', 'he', 'd oes', "n't", 'always', 'agree', 'with', 'it', '.', 'I', 'just', 'f ound', 'it', 'odd', '\x85 ', 'a', 'real', 'change', 'of', 'heart', '.', 'Across', 'from', 'him', 'is', 'a', 'stupendous', 'performanc e', 'by', 'his', 'beau', 'at', 'the', 'time', 'Sondra', 'Locke', ' .', 'Her', 'turn', 'of', 'traumatic', 'torment', '(', 'being', 'se nselessly', 'raped', 'along', 'with', 'her', 'younger', 'sister', ')', ',', 'is', 'hidden', 'by', 'a', 'glassily', 'quiet', 'intensi ty', '.', 'When', 'the', 'anger', 'is', 'released', ',', 'it', "'s ", 'tactically', 'accurate', 'in', 'its', 'outcome', '.', 'Paul', 'Drake', 'is', 'perfectly', 'menacing', 'and', 'filthy', 'as', 'on e', 'of', 'the', 'targeted', 'thugs', 'and', 'Audrie', 'J.', 'Neen an', 'nails', 'down', 'a', 'repellently', 'scummy', 'and', 'big', '-', 'mouthed', 'performance', '.', 'These', 'people', 'are', 'tru ly', 'an', 'ugly', 'bunch', 'of', 'saps', '.', 'Pat', 'Hingle', 'is', 'sturdy', 'as', 'the', 'Chief', 'of', 'the', 'small', 'coastal ', 'town', '.', 'In', 'smaller', 'parts', 'are', 'Bradford', 'Dill man', 'and', 'the', 'agreeably', 'potent', 'Albert', 'Popwell', '(', 'a', 'regular', 'in', 'the', 'series', '1', '-', '4', ',', 'but ', 'under', 'different', 'characters', ')', '.', 'How', 'can', 'yo u', 'forget', 'him', 'in', "'", 'Dirty', 'Harry', "'", '\x85 ', 'y es', 'he', 'is', 'bank', 'robber', 'that', "'s", 'at', 'the', 'end ', 'of', 'the', 'trademark', 'quote', '"', 'Do', 'I', 'feel', 'luc ky', '?', 'Well', ',', 'do', 'ya', ',', 'punk', '?', '"'], 'label' : 'pos'}

In [6]:

```
In [7]:
print(f'Number of training examples: {len(train_data)}')
print(f'Number of validation examples: {len(valid data)}')
Number of training examples: 17500
Number of validation examples: 7500
In [11]:
vocab size = 25000
TEXT.build vocab(train data, max size = vocab size)
LABEL.build_vocab(train_data)
In [12]:
TEXT.vocab.freqs.most common(20)
Out[12]:
[('the', 204019),
   ,', 193654),
 ('.', 166331),
 ('and', 110329),
 ('a', 110150),
 ('of', 101409),
 ('to', 94242),
 ('is', 76799),
 ('in', 61400),
 ('I', 54426),
 ('it', 54053),
 ('that', 49499),
 ('"', 44109),
 ("'s", 43703),
 ('this', 42479),
 ('-', 37154),
 ('/><br', 36011),
 ('was', 35256),
 ('as', 30408),
 ('with', 30268)]
In [13]:
TEXT.vocab.itos[:10]
Out[13]:
```

Реализуйте и обучите двунаправленную рекуррентную сеть (LSTM или GRU).

['<unk>', '<pad>', 'the', ',', '.', 'and', 'a', 'of', 'to', 'is']

```
In [14]:
```

```
batch_size = 32
device = 'cuda'

train_iterator, valid_iterator, test_iterator = data.BucketIterator.splits(
    (train_data, valid_data, test_data),
    batch_size = batch_size,
    device = device
)
```

In [15]:

```
input_size = len(TEXT.vocab)
embedding_size = 100
hidden_size = 256
output_size = 1
learning_rate = 0.001
pad_idx = TEXT.vocab.stoi[TEXT.pad_token]
```

In [50]:

```
from model import RNN
model = RNN(input_size, embedding_size, hidden_size, output_size, pad_idx)
```

In [17]:

```
optimizer = torch.optim.AdamW(model.parameters(), lr=learning_rate)
logs_writer = SummaryWriter(log_dir='./logs/rnn')
criterion = nn.BCEWithLogitsLoss()
```

In [18]:

```
model = model.to(device)
criterion = criterion.to(device)
```

In [25]:

```
from train import train

train(model, train_iterator, valid_iterator, optimizer, criterion, logs_writer
, 5)
```

In [27]:

100%

```
test_loss, test_acc = evaluate(model, test_iterator, criterion)
print(f'Test Loss: {test_loss:.3f} | Test Acc: {test_acc*100:.2f}%')
```

Test Loss: 0.482 | Test Acc: 77.93%

5/5 [11:03<00:00, 132.71s/it]

Используйте индексы слов и их различное внутреннее представление (word2vec, glove).

In [51]:

```
from torchtext.vocab import GloVe
# build the vocabulary
embedding_size = 100
TEXT.build_vocab(train_data, max_size = vocab_size, vectors=GloVe(name='6B', d
im=embedding_size))
LABEL.build_vocab(train_data)
```

In [52]:

```
model = RNN(input_size, embedding_size, hidden_size, output_size, pad_idx)
```

In [53]:

```
pretrained_embeddings = TEXT.vocab.vectors
print(pretrained_embeddings.shape)
```

torch.Size([25002, 100])

In [54]:

```
model.embedding.weight.data.copy_(pretrained_embeddings)
```

Out[54]:

```
tensor([[ 0.0000, 0.0000, 0.0000, ..., 0.0000,
                                                  0.0000,
                                                           0.000
0],
       [ 0.0000, 0.0000,
                           0.0000, ..., 0.0000,
                                                  0.0000,
                                                           0.000
0],
       [-0.0382, -0.2449,
                           0.7281, \ldots, -0.1459,
                                                  0.8278,
                                                           0.270
6],
       [ 0.0000, 0.0000, 0.0000, ..., 0.0000,
                                                  0.0000,
                                                           0.000
0],
                           0.0000, ..., 0.0000,
       [ 0.0000,
                 0.0000,
                                                  0.0000,
                                                           0.000
0],
       [ 0.0000, 0.0000,
                           0.0000, ..., 0.0000,
                                                  0.0000,
                                                           0.000
0]])
```

```
In [55]:
```

```
pad idx = TEXT.vocab.stoi[TEXT.pad token]
unk idx = TEXT.vocab.stoi[TEXT.unk token]
model.embedding.weight.data[unk idx] = torch.zeros(embedding size)
model.embedding.weight.data[pad idx] = torch.zeros(embedding size)
print(model.embedding.weight.data)
tensor([[ 0.0000, 0.0000, 0.0000, ..., 0.0000, 0.0000,
                                                           0.000
0],
       [ 0.0000, 0.0000, 0.0000, ..., 0.0000,
                                                  0.0000,
                                                           0.000
0],
       [-0.0382, -0.2449, 0.7281, ..., -0.1459, 0.8278,
                                                           0.270
6],
       [ 0.0000, 0.0000, 0.0000, ..., 0.0000, 0.0000,
                                                           0.000
0],
       [ 0.0000, 0.0000, 0.0000, ..., 0.0000, 0.0000,
                                                           0.000
0],
       [ 0.0000, 0.0000, 0.0000, ..., 0.0000, 0.0000, 0.000
0]])
```

In [56]:

```
batch_size = 32
device = 'cuda'

train_iterator, valid_iterator, test_iterator = data.BucketIterator.splits(
    (train_data, valid_data, test_data),
    batch_size = batch_size,
    device = device
)
```

In [57]:

```
input_size = len(TEXT.vocab)
hidden_size = 256
output_size = 1
learning_rate = 0.001
```

In [58]:

```
optimizer = torch.optim.AdamW(model.parameters(), lr=learning_rate)
logs_writer = SummaryWriter(log_dir='./logs/glove')
criterion = nn.BCEWithLogitsLoss()
```

In [59]:

```
model = model.to(device)
criterion = criterion.to(device)
```

```
In [60]:
```

```
train(model, train_iterator, valid_iterator, optimizer, criterion, logs_writer
, 5)
```

```
0% | 0/5 [00:00<?, ?it/s]

20% | 1/5 [02:12<08:48, 132.11s/it]

40% | 2/5 [04:25<06:37, 132.45s/it]

60% | 3/5 [06:37<04:24, 132.34s/it]

80% | 4/5 [08:51<02:12, 132.91s/it]

100% | 5/5 [11:06<00:00, 133.23s/it]
```

In [61]:

```
test_loss, test_acc = evaluate(model, test_iterator, criterion)
print(f'Test Loss: {test_loss:.3f} | Test Acc: {test_acc*100:.2f}%')
```

Test Loss: 0.356 | Test Acc: 87.19%

Поэкспериментируйте со структурой сети (добавьте больше рекуррентных, полносвязных или сверточных слоев).

In [71]:

```
from model import RNN2
model = RNN2(input_size, embedding_size, hidden_size, output_size, pad_idx)
```

In [72]:

```
pretrained_embeddings = TEXT.vocab.vectors
model.embedding.weight.data.copy_(pretrained_embeddings)

pad_idx = TEXT.vocab.stoi[TEXT.pad_token]
unk_idx = TEXT.vocab.stoi[TEXT.unk_token]

model.embedding.weight.data[unk_idx] = torch.zeros(embedding_size)
model.embedding.weight.data[pad_idx] = torch.zeros(embedding_size)
```

In [75]:

```
optimizer = torch.optim.AdamW(model.parameters(), lr=learning_rate)
logs_writer = SummaryWriter(log_dir='./logs/rnn-additional_fc')
criterion = nn.BCEWithLogitsLoss()
```

In [76]:

```
model = model.to(device)
criterion = criterion.to(device)
```

In [77]:

 $\label{lem:condition} train_iterator, \ valid_iterator, \ optimizer, \ criterion, \ logs_writer, \ 5)$

```
0% | 0/5 [00:00<?, ?it/s]

20% | 1/5 [02:13<08:54, 133.55s/it]

40% | 2/5 [04:27<06:40, 133.63s/it]

60% | 3/5 [06:40<04:26, 133.44s/it]

80% | 4/5 [08:54<02:13, 133.75s/it]


100% | 5/5 [11:08<00:00, 133.78s/it]
```

In [78]:


```
test_loss, test_acc = evaluate(model, test_iterator, criterion)
print(f'Test Loss: {test_loss:.3f} | Test Acc: {test_acc*100:.2f}%')
```

Test Loss: 0.407 | Test Acc: 84.31%


Accuracy



Itearation_Loss



Loss



Вывод:

В данной работе была реализованная рекуррентная сеть для анализа текста, были использованные разные модели сети и способы векторизации текста.